

# **ANÁLISIS DE LA DEMANDA ELÉCTRICA EN ESPAÑA MEDIANTE SERIES TEMPORALES.**

**Determinación de variables exógenas**

Alumno: Bernardo José Llamas Verna


Tutor: Lino González García

Máster Universitario en Ciencia de Datos

Universidad Camilo José Cela


## OBJETIVOS.

- Análisis y obtención de los patrones que rigen la demanda eléctrica en el Estado español para el período (2014-2021).
- Modelado de la demanda eléctrica.
- Extracción de **variables exógenas** con las que enriquecer los modelos.



Variable cuyo valor se determina fuera del modelo y se impone en dicho modelo sin ser afectada por él.

## ESTADO DEL ARTE SOBRE DETERMINACIÓN DE VARIABLES EXÓGENAS PARA EL ESTUDIO DE DEMANDA ELÉCTRICA.

 **Ramón Christen et al. (2020):** Se pueden determinar hasta **50 variables exógenas** divididas en las siguientes **categorías** que no tienen la misma influencia sobre la variable de estudio.

- **Variables climáticas:** humedad, precipitación, temperatura, viento, climáticas, etc.
- **Calendario:** fechas, eventos señalados, vacaciones, Navidad, etc.
- **Información del día:** si el día es antes/después de un festivo, día laboral, etc.
- **Socioeconómico:** tendencias de la economía, PIB, tasa de empleo, etc.
- **Información demográfica:** tasa de nacimientos, número de habitantes, número de viviendas, etc.
- **Otros:** sensores, aparatos conectados a la red, etc.



## EXTRACCIÓN DE DATOS

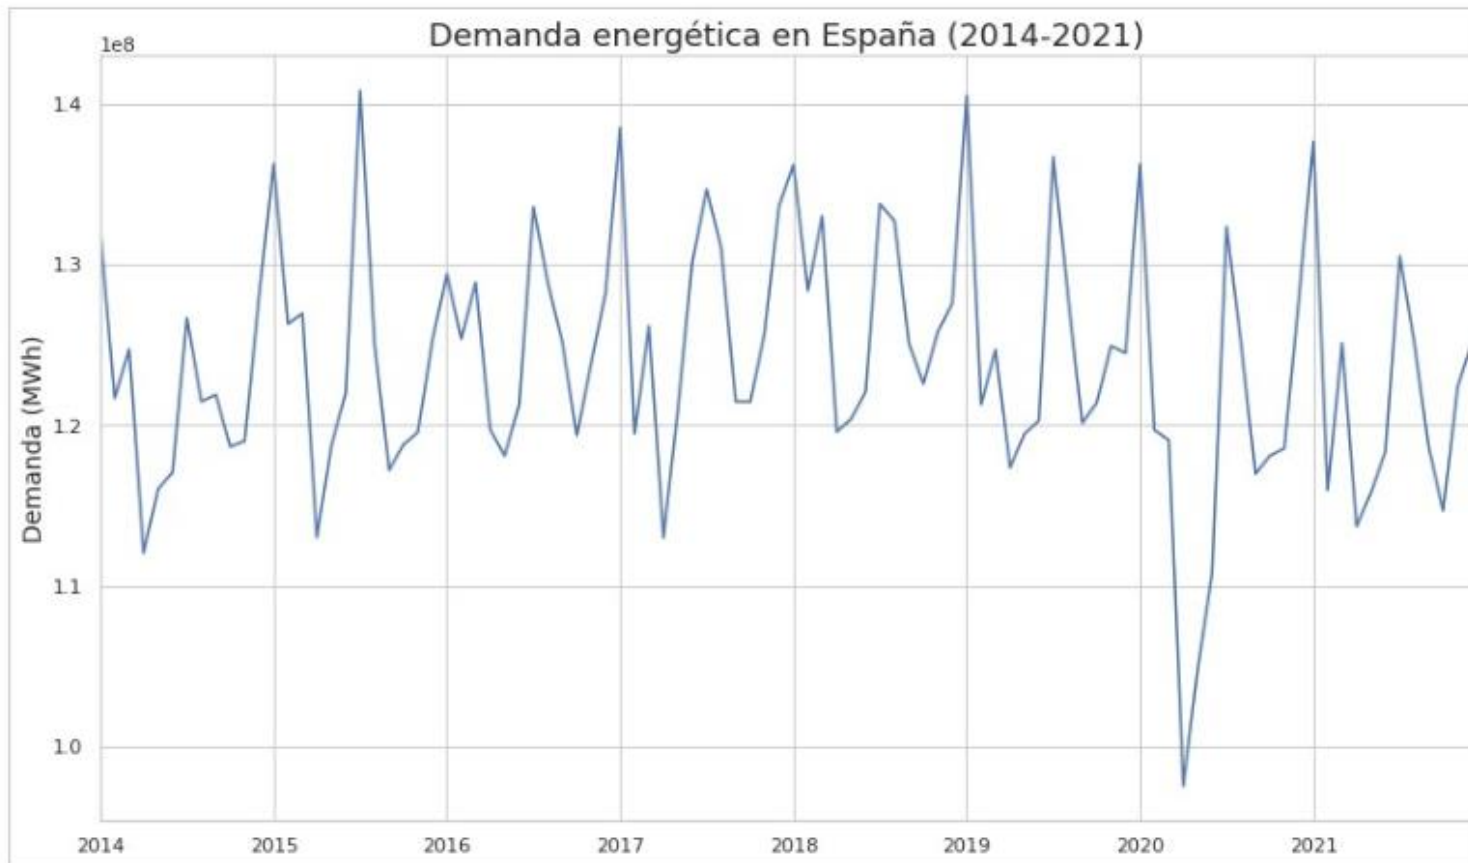
### DEMANDA ELÉCTRICA

- **Red Eléctrica (API e.sios)**
  - Extracción de datos de demanda eléctrica por día período (2014-2021).

### TEMPERATURA

- **Copernicus Climate Data Store**
  - Datos diarios de temperatura para 5 ciudades españolas.  
(Madrid, Barcelona, Valencia, Sevilla, Bilbao)



# ANÁLISIS EXPLORATORIO DE LA DEMANDA



- Distribución periódica anual.
- Márgenes de consumo entre  $(1.1-1.4) \cdot 10^8$  MWh.
- Caída abrupta de la demanda en 2020 por irrupción del COVID-19.

# ANÁLISIS EXPLORATORIO DE LA DEMANDA

## DISTRIBUCIÓN ANUAL Y MENSUAL



### DISTRIBUCIÓN ANUAL



- Demanda creciente hasta 2018.
- 2020 año de mayor variabilidad por COVID.

### DISTRIBUCIÓN MENSUAL




↑ **Enero** mes de mayor consumo promedio.

↓ **Abril** mes de menor consumo promedio.

- Meses de invierno y verano, mayor demanda.
- Meses de otoño y primavera, menor demanda.

# ANÁLISIS EXPLORATORIO DE LA DEMANDA



- Tendencia al alza hasta el 2018, posible estancamiento económico.
- Periodicidad anual marcada por las estaciones.
- Serie no estacionaria (test de Dickey-Fuller).
- ACF y PACF muestran una autocorrelación entre valores que permite modelos autorregresivos.

# ANÁLISIS DE LA DEMANDA DIARIA


## Días laborables (L-V):

Consumo promedio parecido

## Fin de semana (S-D):

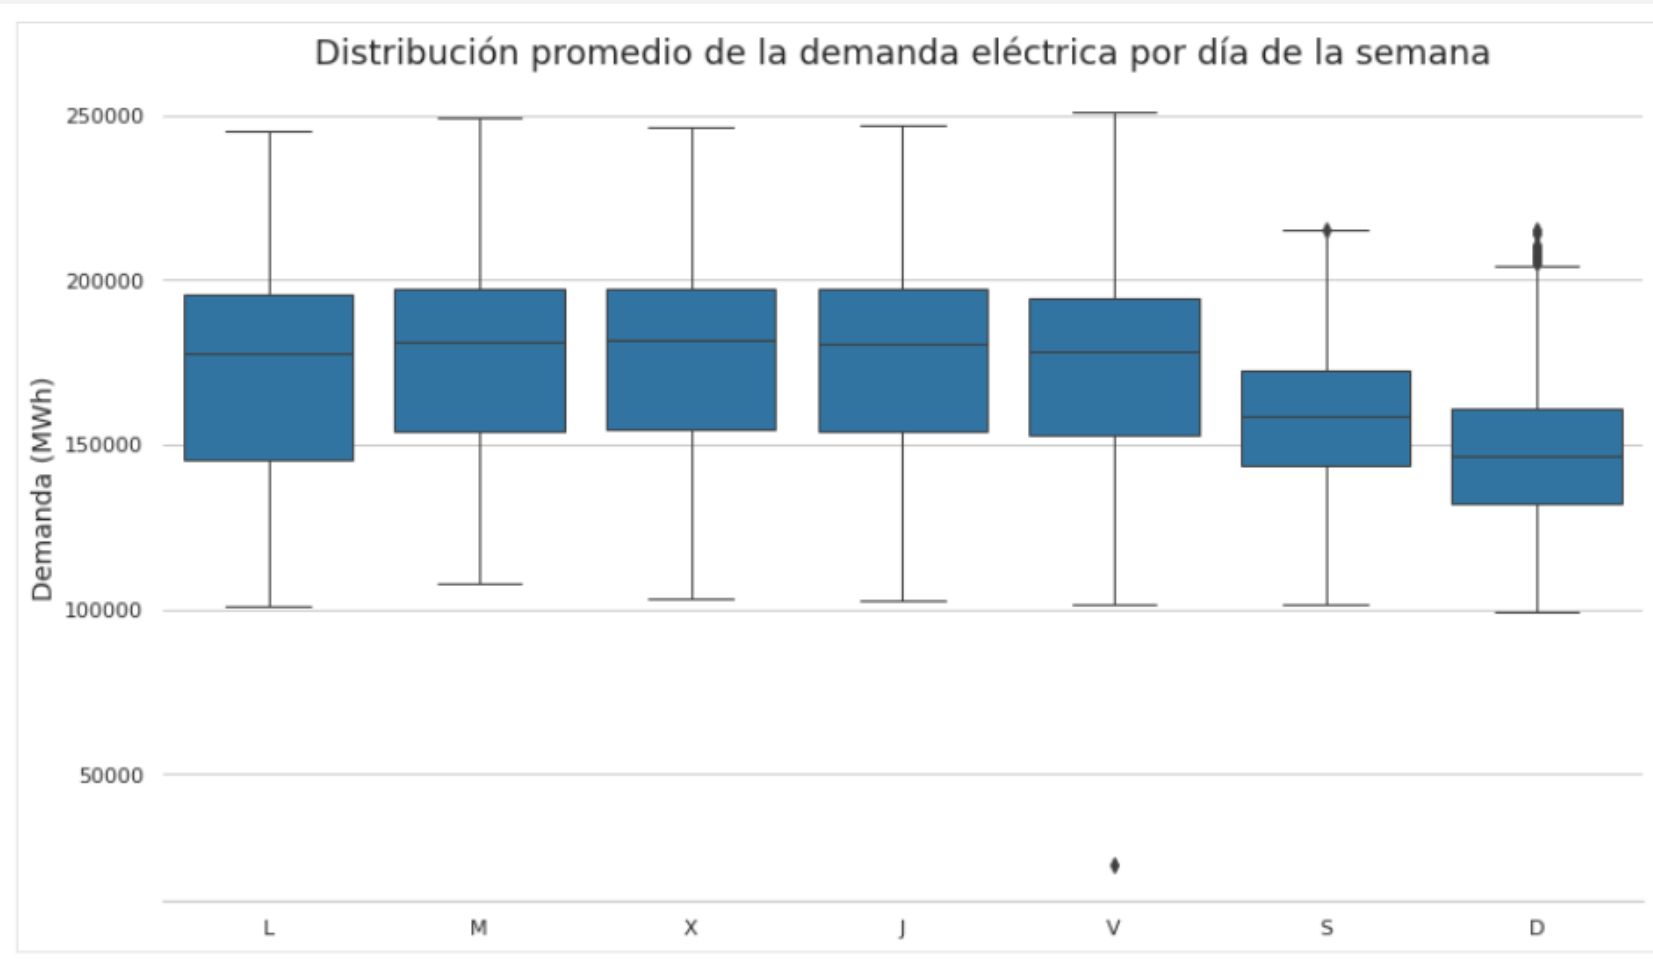
Consumo promedio reducido.

Domingo día de menor consumo.





# ANÁLISIS DE LA DEMANDA DIARIA



**Días laborables (L-V):**


Consumo promedio parecido

**Fin de semana (S-D):**

Consumo promedio reducido.

Domingo día de menor consumo.

# ANÁLISIS DE LA DEMANDA DIARIA (FESTIVOS)




Podemos ver cómo afectan los festivos a la demanda eléctrica.

Los festivos en promedio suponen una demanda un 8% menor que en un día laboral.

## INFLUENCIA DE LA TEMPERATURA EN LA DEMANDA

- Se puede confirmar la influencia de la temperatura sobre la demanda energética
- La influencia es de aumento de la demanda para valores extremos (por debajo de los 15°C y por encima de los 20°C)



## VARIABLES EXÓGENAS

- **Día de la semana** (weekday) (0-6 lunes-domingo)
- **Días laborables** (working\_day) (1) / Festivos (0)
- **Temperatura promedio** en 5 ciudades.
- **Estacionalidad** (invierno/verano).
  - ⇒ Booleans (is\_winter/is\_summer).

# DATASET RESUMEN CON VARIABLES EXÓGENAS

	value	weekday	working_day	madrid_temp	barcelona_temp	bilbao_temp	sevilla_temp	valencia_temp	is_winter	is_summer
date										
2014-01-01	3315035.0	2.0	0.0	6.785193	8.006851	11.418970	12.184413	13.189499	1	0
2014-01-02	4059590.0	3.0	1.0	9.109185	10.764683	12.935602	14.524325	15.136449	1	0
2014-01-03	4098986.0	4.0	1.0	9.776889	11.935958	13.029657	15.653018	16.565861	1	0
2014-01-04	3867911.0	5.0	1.0	6.703811	11.307489	9.814500	14.106683	14.699295	1	0
2014-01-05	3648038.0	6.0	1.0	5.285333	8.682916	9.971085	10.653680	10.970076	1	0
...	...	...	...	...	...	...	...	...	...	...
2021-12-27	3686647.0	0.0	1.0	11.606002	13.531011	14.285517	17.009720	17.443636	1	0
2021-12-28	3729169.0	1.0	1.0	9.792129	14.261092	14.133620	16.015375	16.007968	1	0
2021-12-29	3692921.0	2.0	1.0	8.401157	13.250848	12.936356	13.320164	15.173263	1	0
2021-12-30	3689439.0	3.0	1.0	7.203344	11.992122	12.347234	12.666560	12.678245	1	0
2021-12-31	3331056.0	4.0	1.0	8.081628	11.068301	12.862481	13.293043	11.608819	1	0

2922 rows × 10 columns

# MODELOS DE SERIES TEMPORALES Y MÉTRICAS

## MODELOS

- Holt-Winters (baseline model)
- SARIMAX
- XGBoost
- Prophet

## MÉTRICAS


- MAE
- MSE
- RMSE
- MAPE
- SMAPE
- MASE

## 4 ESCENARIOS

**Aplicamos los modelos sobre diferentes escenarios para ver cómo afectan las variables exógenas:**

- Ⓐ Sin variables exógenas
- Ⓑ Día de la semana y día laboral/festivo.
- Ⓒ Día de la semana, laboral/festivo y temperatura.
- Ⓓ Día de la semana, laboral/festivo, temperatura y estacionalidad (invierno, verano).


# PREDICCIONES MARZO 2022



- Todos los modelos son mejores que **HW**.
- **SARIMAX** mantiene muy bien la estacionalidad diaria.
- **XGBoost y Prophet** siguen bien las predicciones pero aumentan los errores con el tiempo.
- **Prophet** mejor modelo.



# PREDICCIONES MARZO 2022 (ERRORES)



- Errores de **Prophet** en promedio menores que **XGBoost**.
- Márgenes de error de **XGBoost** bastante grandes cuando hay picos de demanda.
- Preferencia por **Prophet** por permitir una predicción de demanda más cercana al valor real cuando hay picos de consumo.

## CONCLUSIONES

⇒ Hay variables exógenas que penalizan la precisión de los modelos (is\_winter/is\_summer)

- La temperatura a veces ha llegado a penalizar también en ciertos modelos.

⇒ Aparentemente más peso días de la semana y festivos.

- Peso decisivo de los patrones de consumo. Caso español, país de temperaturas suaves.

⇒ Prophet es el mejor modelo en la mayoría de escenarios y métricas.

⇒ SARIMAX destaca muchas veces como mejor modelo en el escenario B para MAE, MAPE y sMAPE.

⇒ XGBoost da métricas muy parecidas en cada escenario.

## SIGUIENTES PASOS

- ⇒ Temperatura: investigar si el considerar la temperatura media de cada día en cada una de las cinco ciudades consideradas es acertado.
  - Aumentar la granularidad: pasar a datos horarios de temperatura.
  - Más ciudades (Coruña)
- ⇒ Estacionalidad: otro tratamiento o descartarlas.
- ⇒ Población: funcionaría como un peso que aumentase/disminuyese la influencia de la temperatura.
- ⇒ Días laborables y festivos: realizar una investigación más granular (caso del viernes, festivos según día de la semana, post-festivos)
- ⇒ Descomposición demanda: hogares/industria
- ⇒ Redes Neuronales.

¡MUCHAS GRACIAS!